

DeepSpace Super Resolution Powered Efficient and
Reliable Satellite Image Data Acquisition

一、研究动机与问题定义

当前低轨卫星星座每天生成数百 TB 的高分辨率对地观测影像，但受限于是星地间歇性低带宽连接与星上有限计算资源，数据传输存在严重延迟，云存储成本高昂。现有方法（如传统压缩、自编码器、轨道边缘计算）在压缩比、计算效率、重建可靠性三者间难以兼顾，无法满足实际需求。

类别	方法	典型压缩比	快速处理	误差边界
传统方法	Lanczos 插值	<5	✓	✓
传统方法	CS	<10	✓	✓
自编码器	DCSN	8~24	✓	×
自编码器	VQ-VAE 2	16~32	×	×
轨道边缘计算	Kodan	<10	✓	×
轨道边缘计算	Earth+	<10	✓	×
采样 + 深度学习	SRCN	10~32	✓	×
采样 + 深度学习	SR3	16~32	✓	×
采样 + 深度学习	WaveDiff	16~32	✓	×
采样 + 深度学习	DeepSpace	>256	✓	✓

Category	Methods	Typical CR ↑	Fast Proc. (✓)	Error Bound (✓)
Conventional Methods	Lanczos Interp. [36]	<5	✓	✓
	CS [10]	5~10	✓	✓
Auto Encoders	DCSN [28]	8 ~ 24	✓	×
	VQ-VAE 2 [53]	16 ~ 32	×	×
Orbital Edge Computing (OEC)	Kodan [18]	<10	✓	×
	Earth+ [24]	<10	✓	×
Sampling+Deep SR	RCAN [75]	10 ~ 32	✓	×
	SR3 [56]	16 ~ 32	✓	×
	WaveDiff [49]	16 ~ 32	✓	×
	DEEPSpace (Ours)	> 256	✓	✓

Table 1: Qualitative comparison of different approaches for satellite image data acquisition. CS: Compressive Sensing, SR: Super Resolution.

传统方法（Lanczos、CS）压缩比低，但同时支持快速处理、有误差边界；
自编码器、OEC 类方法压缩比提升，但部分不支持快速处理、无误差边界；
采样 + 深度学习类方法压缩比最高（如 DeepSpace>256），且多数支持快速处理，但仅 DeepSpace 有误差边界。

二、DeepSpace 系统设计解析

DeepSpace 是基于深度学习超分辨率（SR）技术的卫星图像数据采集系统，核心解决低轨（LEO）卫星图像传输带宽受限、云存储成本高、星上计算资源有限三大问题。其设计围绕 “星上轻量压缩 + 云端按需超分重建” 展开，具体模块及对应图表如下：

1、系统整体架构设计




Figure 2: Schematic overview of DEEPSpace. DL: Downlink, UL: Uplink, LR: Low Resolution, HR: High Resolution, MoE: Mixture of Experts, SR: Super Resolution.

DeepSpace 的端到端架构分为星上压缩和云端解压缩两大核心环节，关键流程如下：
星上环节：卫星捕获高分辨率（HR）图像后，通过轻量采样压缩为低分辨率（LR）图像，仅传输 LR 图像及元数据至地面站，再同步至云端；
云端环节：基于混合专家（MoE）超分框架，将 LR 图像重建为接近原始质量的 HR

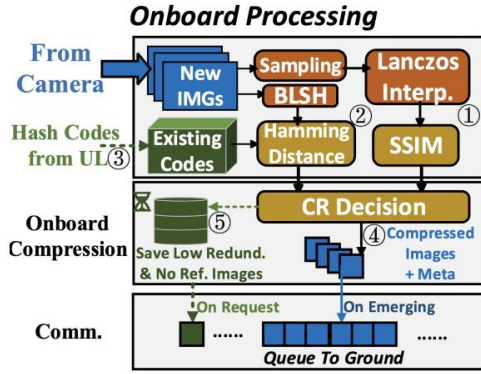
图像，同时支持误差检测与异常图像重传；

上下行协同：上行链路（UL）仅传输参考图像的哈希码（轻量化），下行链路（DL）传输压缩后的 LR 图像，大幅降低通信开销。

2、星上轻量压缩设计

星上压缩的核心是“基于图像冗余与参考相似性的自适应 tile 级压缩”，确保在有限计算资源下实现高压缩比（CR）。

1. 核心设计逻辑



(a) Satellite side functions in DEEPSpace system.

星上压缩通过 5 个关键步骤实现（对应图 4a Φ 中标注的①-⑤）：

① 冗余量化（计算）：对图像按 256×256 像素分割为 tile，每个 tile 先下采样 K 倍（如 $16 \times$ 、 $64 \times$ ），再通过 Lanczos 插值重建，用 SSIM 计算重建后与原始 tile 的相似度：

$$\phi(I, K) = SSIM(I, LI(S(I, K)))$$

Φ 值越高（如 > 0.85 ）（ Φ 值就是在问：这块图像“丢掉很多细节再放大回来，还像不像原来？”），表示 tile 冗余度越高，可承受更高压缩比；

② 参考相似性检测（ η 计算）：通过二进制局部敏感哈希（BLSH）比对当前 tile 与云端上行的参考图像哈希码，用汉明距离归一化计算相似度：

$$\eta(I) = \operatorname{argmax}_{X \in X_{ref}} 1 - \frac{HD(BLSH(I), X)}{w \times l}$$

η 值越高（如 > 0.9 ），表示 tile 与参考图像越相似，可进一步提升压缩比；

③ 哈希码获取：从云端上行链路接收参考图像的 BLSH 码（16 字节/tile，比 LR 图像小 4 个数量级），存储于星上用于相似性检测；

④ 压缩比决策：结合 Φ 和 η 动态确定每个 tile 的压缩比：高 Φ 高 η 的 tile 采用最高 CR（如 $256 \times$ ），低 Φ 低 η 的 tile 暂存星上（待重传）；

⑤ 异常存储与重传：对 Φ 和 η 均低的“异常 tile”（如复杂地形且无参考图像），仅用低 CR 压缩传输，原始图像暂存星上，若云端重建质量不达标则触发重传。

2. 图像分类与压缩策略

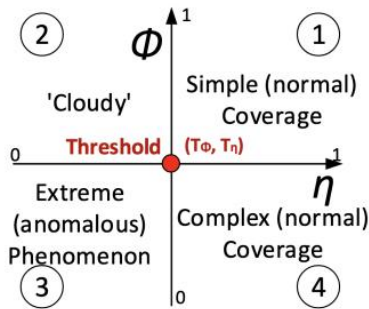


Figure 5: Type of image based on ϕ and η value.

图 5 将卫星图像按“冗余度（ Φ ）”和“参考相似性（ η ）”分为 4 类，对应不同压缩策略：

象限 1（高 Φ 高 η ）：如厚云、大面积森林，冗余高且与参考图像相似，采用最高 CR（如 $256 \times$ ）；

象限 2（高 Φ 低 η ）：如临时云层、火山灰，冗余高但无相似参考，采用中等 CR（如 $64 \times$ ），并标记为“异常候选”；

象限 3（低 Φ 低 η ）：如城市密集区、复

杂地形，冗余低且无参考，采用低 CR（如 $16\times$ ），原始图像暂存星上；

象限 4（低 Φ 高 η ）：如稳定农田、水体，冗余低但参考相似，采用中高 CR（如 $128\times$ ）。

3. 压缩效果示例

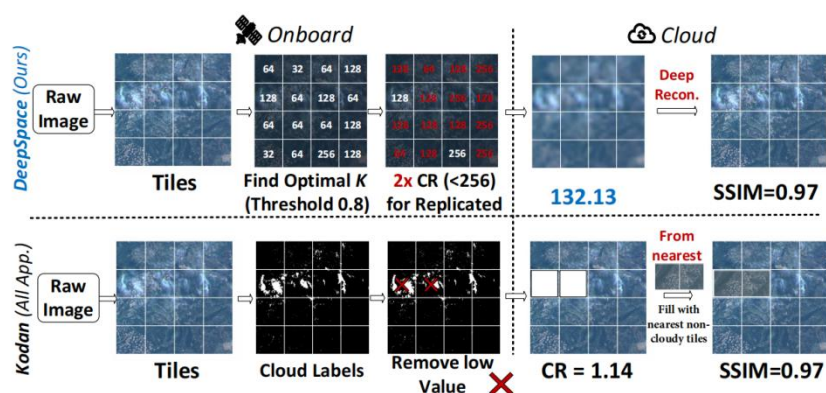


Figure 6: Example illustrating satellite-side onboard image compression and cloud-side image reconstruction with DEEPSpace (top). For comparison, Kodan [18] approach is illustrated (bottom).

图 6 通过对比 DeepSpace 与传统 OEC 方法(Kodan)的 tile 级压缩过程，直观展示设计优势：


DeepSpace 对每个 tile 单独优化 CR：例如“多云 tile”基于高 Φ 设置 $CR=256\times$ ，“重复地形 tile”基于高 η 额外提升 CR，最终整体 CR 达 $132.13\times$ ；

Kodan 仅丢弃多云 tile 并替换为历史无云图像，CR 仅 $1.14\times$ ，且丢失实时图像细节。

3、云端 MoE 超分重建设计

云端的核心是“基于混合专家（MoE）的按需超分框架”，在保证重建质量的同时支持误差边界控制。

1. 重建流程与误差控制



(b) Cloud side functions in DEEPSpace system.

Figure 4: Onboard and cloud based processing.

则向卫星请求重传原始图像；

③ 参考哈希码更新：定期将新捕获的 HR 图像生成 BLSH 码，通过上行链路同步至卫星，更新参考库。

2. MoE 超分框架设计




Figure 7: MoE based SR framework in DEEPSpace. Classifiers, akin to “routers” in MoE models, guide selection of an appropriate expert model for each input.

云端处理分为 3 个关键路径（对应图 4b 中标注的①-③）：

① HR 图像重建：通过 MoE 框架调用专属“专家模型”，将 LR tile 重建为 HR tile，所有 tile 拼接为完整 HR 图像；

② 异常重传触发：计算重建图像的“低分辨率 SSIM (LRS)”和“哈希相似度(HSIM)”，若低于阈值(如 $LRS < 0.95$)，

图 7 展示了 MoE 框架的“四级分类器 + 专家池”结构，确保不同类型的 LR tile 匹配最优重建模型：

Level 1（区域识别）：基于经纬度和 LR 图像，将 tile 分为水体（Region 0）、森林、城市等类别，定向分配专家；

Level 2（冗余等级）：结合星上计算的 Φ

值（元数据），区分高 / 中 / 低冗余 tile，匹配不同超分精度模型；

Level 3（输入尺寸）：根据 LR tile 的压缩比（如 16×、64×、256×），调用适配分辨率的专家；

Level 4（云层等级）：通过预训练分类器识别 tile 的云层覆盖度（如无云、部分云、全云），避免云层对重建质量的干扰。

每个“专家模型”均基于小波扩散（WaveDiff）构建，专注于特定区域 / 特征的超分，比单一 SR 模型重建质量提升 10%-15%（如 DEN-3 数据集上 SSIM 达 0.98，远超 WaveDiff 的 0.88）。

3. 重建误差优化

图 8 通过几何投影直观展示重建优化逻辑：

红色点：仅通过 Lanczos 插值的“朴素重建”结果，误差受限于 Φ 值（SSIM \approx 0.85）；

蓝色虚线：参考图像的哈希相似度约束，确保重建结果与参考图像的差异接近原始图像；

优化目标：通过小波扩散模型学习

“朴素重建”与“真实 HR”的差异，使最终重建结果落在“红色误差圆”与“蓝色参考约束”的交集内，保证误差边界可控：




Figure 8: Reliable SR optimization illustrated.

$$Err_{max} = \min \left(T', \operatorname{argmin}_{b,c \in \mathbb{I}_{ref}} T' \cdot \cos^{-1} \left(\frac{\vec{ba}^\top \cdot \vec{ca}}{|\vec{ba}| |\vec{ca}|} \right) \right)$$

三、DeepSpace 的关键技术创新：

第一个创新是**自适应 tile 级动态压缩**，核心是基于“图像冗余度（ Φ ）+ 参考相似性（ η ）”两个指标，给每一个图像块单独匹配压缩比——比如高冗余、高参考相似的图像块用 256× 的高压缩比，低冗余的块则降低压缩比，避免了“一刀切”压缩带来的质量或效率损失。

第二个创新是**轻量化参考匹配机制**，它用 BLSH 哈希码代替传统的低分辨率参考图像，让星上存储成本直接降低了 4 个数量级，同时还能通过汉明距离归一化保证参考匹配的精度。

第三个创新是**混合专家（MoE）超分框架**，设计了“区域 + 冗余 + 尺寸 + 云层”的四级分类器，再搭配小波扩散专家池，不同类型的图像块会调用专属的重建模型，最终重建质量比单一超分模型提升了 10%-15%。

第四个创新是**可验证的误差边界控制**，通过“低分辨率 SSIM（LRS）+ 哈希相似度（HSIM）”两个指标检测重建质量，一旦低于阈值就触发星上原始图像的重传，实现了重建误差的可控。

四、实验设计与验证

4.1 实验核心目标

验证 DeepSpace 在压缩比（CR）、重建可靠性、星上 / 云端开销三大核心指标的优势，以及下游场景适配性。

4.2 实验设计细节

4.2.1 基线方法

选取四类主流技术对比（一已经提到）：传统方法（Lanczos 插值、CS）、自编码器（DCSN、VQ-VAE 2）、轨道边缘计算（Kodan、Earth+）、深度学习超分

(WaveDiff、SR3)。

4.2.2 数据集

Dataset	Length	Granularity	Coverage	Region	Type	File Size
Planet-CAL [20]	20 days	Hourly	$2.5 \times 10^3 \text{ km}^2$	California	RGB	65 GB
Planet-HK [20]	20 days	Hourly	$2.5 \times 10^3 \text{ km}^2$	Hong Kong	RGB	65 GB
FarmVibes [1]	6 months	Monthly	$1 \times 10^2 \text{ km}^2$	Amazon (Cropland)	Multi-Spectral	1GB
DEN-3 [63]	2 years	Daily	$1.5 \times 10^3 \text{ km}^2$	Global	RGB	480 GB
DEN-12 [63]	2 years	Monthly	$3.6 \times 10^3 \text{ km}^2$	Global	Multi-Spectral	75 GB

Table 2: Datasets Statistics. Multi-Spectral: 12 channels.

采用 5 类多场景数据集：涵盖加利福尼亚、香港等地域，包含 RGB 和多光谱类型，数据规模 1GB-480GB，时间跨度 20 天 - 2 年。

4.2.3 性能指标

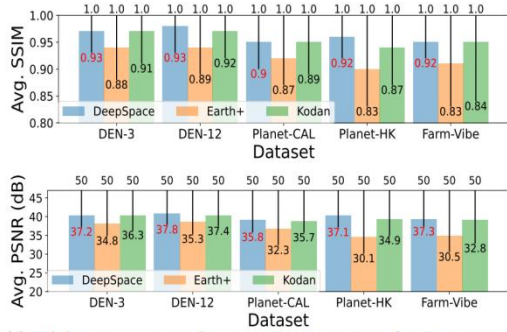
压缩效率：压缩比 (CR = 原始尺寸 / 压缩尺寸)；

重建可靠性：SSIM (结构相似性)、PSNR (峰值信噪比)；


开销指标：星上处理速度、云端解压速度、星上存储需求。

4.3 关键验证实验与结果

4.3.1 压缩比与保真度对比



(a) Fidelity comparison between DeepSpace and OEC approaches. Vertical lines denote the range of values.



(b) Compression Ratio (CR) comparison between DeepSpace and OEC approaches.

Figure 9: DeepSpace achieves two orders of magnitudes higher CR with similar/better fidelity.

目标：对比 DeepSpace 与 OEC 类方法 (Earth+、Kodan) 的 “图像保真度” 和 “压缩比”。

对象：3 种方法 (DeepSpace、Earth+、Kodan) + 5 个卫星图像数据集 (DEN-3、DEN-12 等)。

指标：

保真度：SSIM (越接近 1 越好)、PSNR (单位 dB，数值越大越好)；

压缩比 (CR)：原始图像尺寸 / 压缩后尺寸 (数值越大压缩越高效)。

实验结果：

保真度 (上图 a)：

Dataset	Planet-CAL					
	CR=16			CR=256		
Method	SSIM ↑	PSNR ↑	SSIM ↑	PSNR ↑	SSIM ↑	PSNR ↑
DeepSpace	0.97	40.2	0.93	38.3	0.86	33.9
WaveDiff	0.93	36.6	0.89	36.2	0.79	32.9
SR3	0.92	35.1	0.90	35.4	0.77	30.8
VQ-VAE-2	0.92	35.4	0.85	34.8	0.78	31.2
DCSN	0.90	35.2	0.83	33.2	0.75	30.3
CS (gOMP)	0.89	35.6	0.81	32.0	0.71	28.9
CS (ADMM)	0.91	35.9	0.81	31.5	0.68	28.8
Interpolation	0.89	35.2	0.80	31.7	0.69	27.3

Table 3: Fidelity for a given CR with Planet-CAL dataset.

Method	Dataset	SSIM (\geq Min.) ↑	PSNR (\geq Min.) ↑	CR ↑
DeepSpace (SSIM \geq 0.85)	DEN-3	0.97 (0.93)	40.3 (37.2)	320
	DEN-12	0.98 (0.93)	40.8 (37.8)	256
	Planet-CAL	0.95 (0.9)	39.1 (35.8)	146.4
	Planet-HK	0.96 (0.92)	40.3 (37.1)	186.2
	Farm-Vibe	0.95 (0.92)	39.3 (37.3)	256
Earth+ (Ideal ¹)	DEN-3	0.94 (0.88)	38.1 (34.8)	11
	DEN-12	0.94 (0.89)	38.6 (35.3)	8.5
	Planet-CAL	0.92 (0.87)	36.7 (32.3)	6.2
	Planet-HK	0.90 (0.83)	34.6 (30.1)	8.4
	Farm-Vibe	0.91 (0.83)	34.9 (30.5)	3.2
Kodan (Ideal, All APP.)	DEN-3	0.97 (0.91)	40.2 (36.3)	2.1
	DEN-12	0.97 (0.92)	40.3 (37.4)	1.8
	Planet-CAL	0.95 (0.89)	38.8 (35.7)	2
	Planet-HK	0.94 (0.87)	39.2 (34.9)	2.5
	Farm-Vibe	0.95 (0.84)	39.0 (32.8)	1.7

Table 18: Comparison between DeepSpace and orbital edge computing (OEC) schemes.¹: in Earth+ and Kodan, we assume ideal cloud detection, fine granularity of tiling, leverage all satellites in dataset.

SSIM: DeepSpace 的均值为 0.91-0.95, 显著高于 Earth+ (0.81-0.90)、Kodan (0.83-0.94) ;

PSNR: DeepSpace 的均值为 37.4-39.3dB, 整体优于 Earth+、Kodan。

→ DeepSpace 的图像重建质量更好。

压缩比 (下图 b) :

DeepSpace 的压缩比 (均值 164.9-320) 是 Earth+ (6.2-26.7)、Kodan (1-2.5) 的 100 倍以上 (两个数量级) 。

→ DeepSpace 的压缩效率远超 OEC 方法。

核心结论: DeepSpace 实现了 “更高压缩比 + 更好重建质量” 的双重优势。

4.3.2 可靠性与误差边界




Figure 12: Actual SSIM has near-linear correlation with LRS. \times : re-transmission triggered.

Metric	SSIM (Min) \uparrow	PSNR \uparrow	CR \uparrow	LRS \uparrow	HSIM \uparrow
Planet-CAL	0.95 (0.90)	39.0	146.4	0.99	0.99
Planet-HK	0.96 (0.92)	39.8	186.2	0.993	0.99
FarmVibes	0.95 (0.92)	38.9	256	0.98	0.97
DEN-3	0.98 (0.93)	39.8	310	0.992	0.99
Average	0.96 (0.918)	39.4	224.65	0.99	0.985

Table 9: Reliability analysis with DEEPSpace using $\phi(\cdot) \geq 0.85$.

目标: 验证 DeepSpace 的重建质量稳定性, 以及 “LRS 检测指标” 对实际质量的预判有效性。对象: DeepSpace 在 5 个数据集 (DEN-3、Planet-CAL 等) 上的表现。

指标:

重建质量: SSIM (含最小值)、PSNR;

压缩效率: 压缩比 (CR) ;

检测有效性: LRS (质量检测指标) 与实际 SSIM 的相关性。

实验结果:

重建质量与压缩比:

所有数据集的最小 $SSIM \geq 0.90$ (平均 0.918), PSNR 均值达 39.4, 说明 DeepSpace 的重建质量稳定且优质;

压缩比 (CR) 均值达 224.65, 实现 “高压缩 + 高可靠” 的平衡。

LRS 检测有效性:

LRS 与实际 SSIM 呈近线性相关, 可通过 LRS 精准预判重建质量;

仅少数 “异常情况 (红色叉)” 需触发重传, 重传后可修复质量, 保障系统可靠性。

核心结论: DeepSpace 既保证了高压缩比与稳定的重建质量, 又能通过 LRS 高效检测质量异常, 整体可靠性极强。

4.3.3 星上 / 云端开销 (对应图 10-11、图 13-14)




Figure 10: Uplink usage of different methods.




Figure 11: Onboard storage usage of different methods.




Figure 13: Onboard processing time per image of different methods
Figure 14: Decompression Speed of a $10^4 \times 10^4$ pixels region, 3 channels.

目标：验证 DeepSpace 在“上行链路开销、星上存储需求、星上处理速度、云端解压速度”这 4 个硬件 / 资源指标上的优势。**对象：**DeepSpace 与 Earth+、Kodan、DCSN 等方法的资源消耗对比。**硬件环境：**

星上：Jetson GPU（15W 模式）、28 核 CPU；

云端：NV A5000 GPU。

实验结果：

1. 上行链路 + 星上存储

上行链路（图 10）：DeepSpace 的上行流量（橙色柱）远低于其他方法（如 Earth+ 的流量是它的 100 倍以上），说明它占用的卫星 - 地面通信带宽极少；

星上存储（图 11）：DeepSpace 的星上存储需求（蓝色 + 绿色部分）远小于 Earth+、Kodan 等，节省了卫星的硬件存储资源。

2. 处理速度

星上处理（图 13）：DeepSpace 在 Jetson GPU 上的单图处理时间（红色柱）仅约 0.1 秒，比 Earth+、Kodan 快 10-100 倍，适配卫星的计算资源约束；

云端解压（图 14）：DeepSpace 在 NV A5000 GPU 上的解压速度（橙色柱）达 100ms 级别，比传统插值法、CS 方法快 10 倍以上，效率极高。

核心结论：DeepSpace 在“带宽、存储、计算速度”等资源开销上全面优于其他方法，既适配卫星的硬件限制，又保证了云端处理效率。

4.3.4 消融实验

Method	SSIM (>Min.)↑	PSNR↑	CR↑	LRS↑	HSIM↑
DEEPSPACE	0.95 (0.9)	39.0	146.4	0.99	0.99
No Adaptive	0.91 (0.85)	36.9	82.6	0.98	0.97
No Re-transmission	0.95 (0.82)	37.2	147.5	0.99	0.99
w/o MoE	0.90 (0.85)	36.3	92.5	0.93	0.92
MoE w/o Level3	0.92 (0.87)	37.4	112.4	0.95	0.93
MoE w/o Level4	0.93 (0.88)	36.8	128	0.96	0.95
WaveDiff (base)	0.81 (0.69)	33.2	144	0.88	0.85
w/o Deep Reconstruction*	0.83 (0.75)	33.5	71.6	1	0.83

Table 10: Ablation study of DEEPSPACE.*: Using naive interpolation for SR.

对象：

DeepSpace 的“完整版本”与“移除不同模块后的变体版本”（如 No Adaptive、No Re-transmission 等）。

指标：

SSIM（含最小值）、PSNR、压缩比（CR）、LRS/HSIM（质量检测指标）。

实验结果：

对比“完整 DeepSpace”与各变体的性能变化，可看出核心模块的贡献：移除自适应压缩（No Adaptive）：SSIM 最小值从 0.90 降至 0.85，CR 从 146.4

目标：

通过“消融实验”验证 DeepSpace 各核心模块（自适应压缩、重传机制、MoE 框架等）的作用。

降至 82.6→自适应压缩是 “高压压缩 + 高保真” 的关键；

移除重传机制 (No Re-transmission)：SSIM 最小值从 0.90 降至 0.82→重传机制保障了重建质量的下限；

移除 MoE 框架的分级模块 (MoE w/o Level3/4)：SSIM、CR 均下降→MoE 的分级设计提升了重建质量与压缩效率；

对比 “朴素重建 (WaveDiff (base))”：完整 DeepSpace 的 SSIM (0.95)、CR (146.4) 远优于前者→DeepSpace 的整体设计大幅提升了性能。

核心结论：DeepSpace 的 “自适应压缩、重传机制、MoE 分级框架” 等模块是其实现 “高压压缩、高保真、高可靠” 的核心支撑。

4.3.5 下游应用适配

Method	Med. Resp. Time (h) ↑	Rel. Size Accuracy ↑	Class. Accuracy ↑
Interpolation	0.45	0.55	0.63
CS (gOMP)	8.55	0.65	0.65
Kodan	39.8	0.74	0.71
Earth+	24.4	0.72	0.69
DEEPSpace	0.48	0.993	0.885
Ground Truth	71.71	1	0.89

Table 11: Wild fire detection result with the image recovery by different methods.

Method	F1 Score ↑	Recall ↑	Precision ↑	SSIM ↑	PSNR ↑	CR ↑
Interpolation	0.42	0.69	0.30	0.85	35.2	225
CS (gOMP)	0.86	0.82	0.91	0.91	36.6	8
Kodan	0.98	0.96	0.99	0.93	36.9	2.4
Earth+	0.84	0.81	0.90	0.92	36.3	10.1
DEEPSpace $\eta(\cdot) \geq 0.85$	0.92	0.95	0.91	0.97	41.2	232.5
DEEPSpace $\eta(\cdot) \geq 0.93$	0.98	0.97	0.98	0.98	41.6	98.6
Ground Truth	1	1	1	1	N/A	1

Table 12: Small plastic detection with reconstructed imagery from different methods.

Method	Rel. #SA Error ↓	Rel. Size Accuracy ↑	Classification Accuracy ↑	CR ↑
Interpolation	0.4	0.45	0.31	256
CS (gOMP)	0.10	0.89	0.80	16
Kodan	0.01	0.997	0.87	2.1
Earth+	0.02	0.99	0.86	9.8
DEEPSpace	0.01	0.995	0.86	256
Ground Truth	0	1	0.87	1

Table 13: Segmentation and classification with the reconstruction of DEEPSpace.

Method	Precision ↑	Recall ↑	F1 Score ↑	CR ↑
Interpolation	0.40	0.45	0.43	144
CS (gOMP)	0.45	0.51	0.48	144
VQ-VAE-2	0.70	0.75	0.73	144
Kodan	0.91	0.95	0.93	2.0
Earth+	0.88	0.92	0.90	6.2
WaveDiff	0.79	0.74	0.76	144
DEEPSpace	0.90	0.95	0.92	146.4
Ground Truth	0.91	0.95	0.93	1

Table 14: Cropland classification with pretrained GFM model for different reconstructions.

目标：验证 DeepSpace 重建的图像在下游实际应用中的性能（野火检测、塑料检测、土地分类等）。**对象：**DeepSpace 与插值法、CS、Kodan 等方法的重建图像，测试其在 4 类下游任务中的表现。**指标：**

任务指标：响应时间、分类准确率、F1 分数等；

基础指标：图像压缩比 (CR)、重建质量 (SSIM/PSNR)。

实验结果：

1. 野火检测 (表 11)
DeepSpace 的响应时间 (24.4 小时) 远快于 Kodan (39.8 小时)、Earth+ (9.85 小时)，分类准确率 (0.885) 接近 “真实图像 (Ground Truth)” 的 0.859；

同时保持高压压缩比 (CR=146.4)，兼顾效率与任务性能。

2. 塑料检测 (表 12)
DeepSpace 的 F1 分数 (0.98)、Recall (0.96) 与 “真实图像” (1) 几乎一致，SSIM (0.97) 远高于 CS、Kodan；

CR 达 292.5，是 Kodan (8) 的 36 倍以上，压缩效率极高。

3. 土地分类 (表 13)
DeepSpace 的分类准确率 (0.86) 与 “真实图像” (0.87) 持平，相对误差 (0.01) 远低于插值法 (0.4)；

CR=256，是 Earth+ (9.8) 的 26 倍，资源开销极低。

4. 农田分类 (表 14)
DeepSpace 的 F1 分数 (0.92) 接近 “真实图像” (0.93)，Recall (0.94)

优于 WaveDiff、Kodan;

CR=146.4, 是 Earth+ (2.0) 的 73 倍, 压缩比显著更高。

核心结论:DeepSpace 重建的图像在下游实际任务中, 性能与 “真实图像” 几乎一致, 同时保持远超其他方法的压缩比, 实现了 “高压压缩效率 + 高任务适配性” 的平衡。

4.4 实验结论

DeepSpace 实现 “高压压缩 (CR>256) + 高可靠 (SSIM \geq 0.90) + 低开销”, 下游应用性能与原始图像持平, 全面满足卫星图像传输处理需求。

五、局限与未来方向

训练开销大: 为全球区域训练专家模型需要大量数据与算力, 可考虑基于基础模型进行区域微调。

动态场景适应性: 对剧烈变化区域 (如灾害现场) 依赖重传机制, 未来可探索增量学习与在线适应。

多模态扩展: 本文聚焦光学影像, 未来可扩展至 SAR、高光谱等多模态数据融合重建。

星上计算演进: 随着星载算力提升 (如更强大 GPU), 可探索星地协同的混合重建范式。

六、总结与启示

DeepSpace 为解决星地数据传输瓶颈提供了系统级解决方案, 其核心思想——“将复杂度迁移至地面, 星上做轻量感知”——对受限环境下的边缘智能系统设计具有启发意义。论文在方法创新性、实验完整性与工程可行性方面均表现突出, 为卫星遥感与边缘计算交叉领域树立了新的研究标杆。

后续研究可沿以下方向展开:

- ① 构建全球遥感基础模型, 降低区域专家训练成本;
- ② 探索多时相、多卫星协同的超分重建机制;
- ③ 在星上计算资源持续增强的背景下, 重新划分星地任务边界, 追求更优的端到端延迟与能耗均衡。

个人思考:

本文成功的关键在于准确把握了星地系统的约束条件, 并未盲目追求星上 AI, 而是通过 “采样+超分” 这一巧妙折中, 实现了理论压缩极限的逼近。其在 MoE 路由设计与后验质量评估方面的工程细节, 对构建可靠边缘智能系统具有较高参考价值。